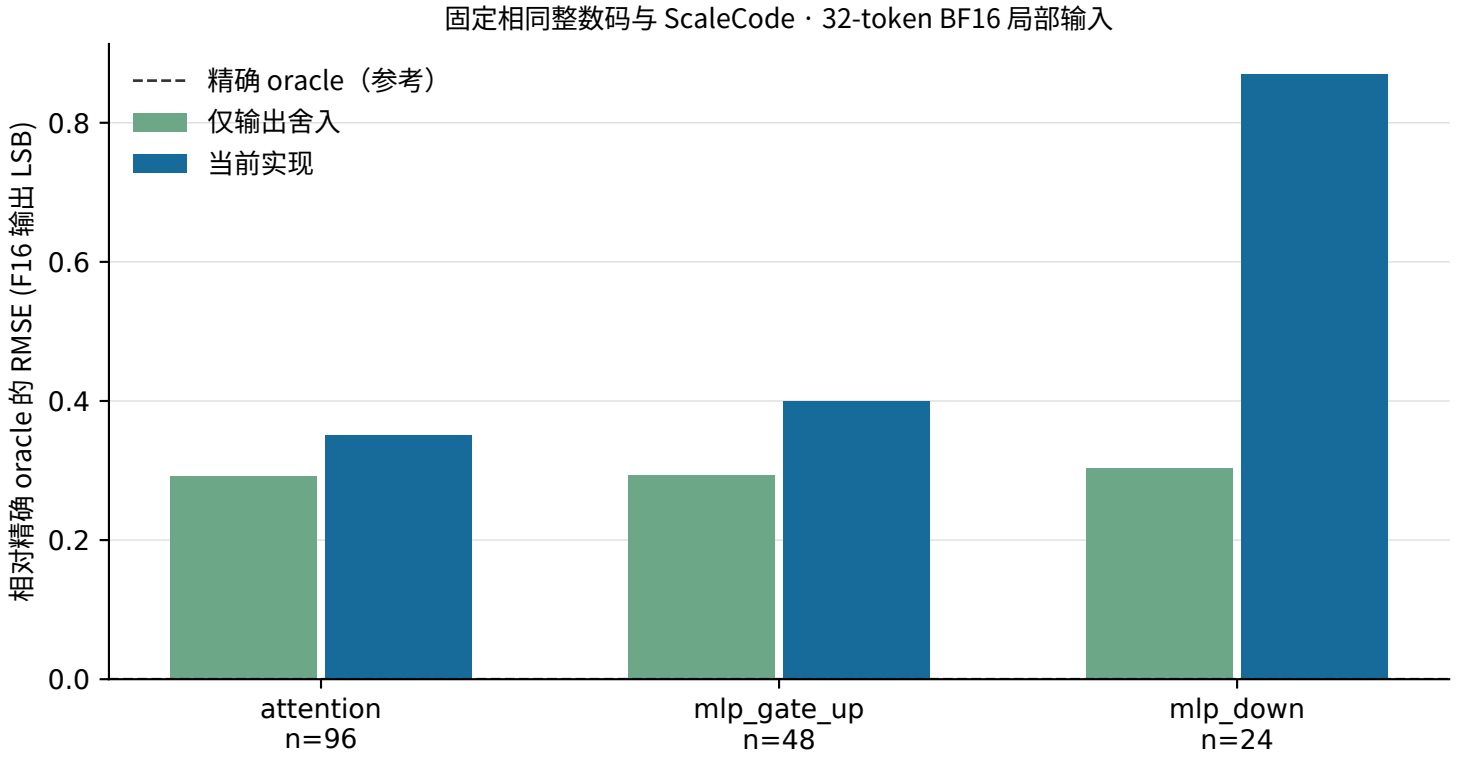
固定相同整数码与 ScaleCode · 32-token BF16 局部输入
精确 oracle（参考）
仅输出舍入
当前实现
相对精确 oracle 的 RMSE (F16 输出 LSB)
0.0
0.2
0.4
0.6
0.8
attention
n=96
mlp_gate_up
n=48
mlp_down
n=24