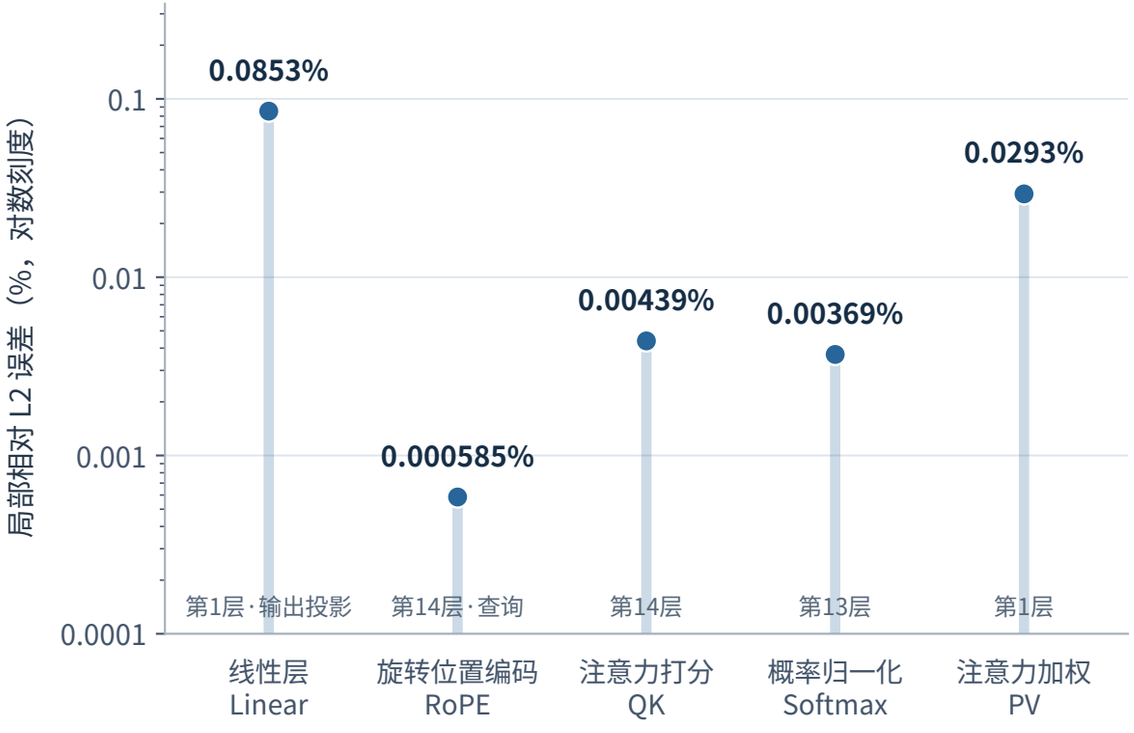
开发检查：1 篇文档，32 token，尚非正式统计

当前实现与保留中间精度的参考比较

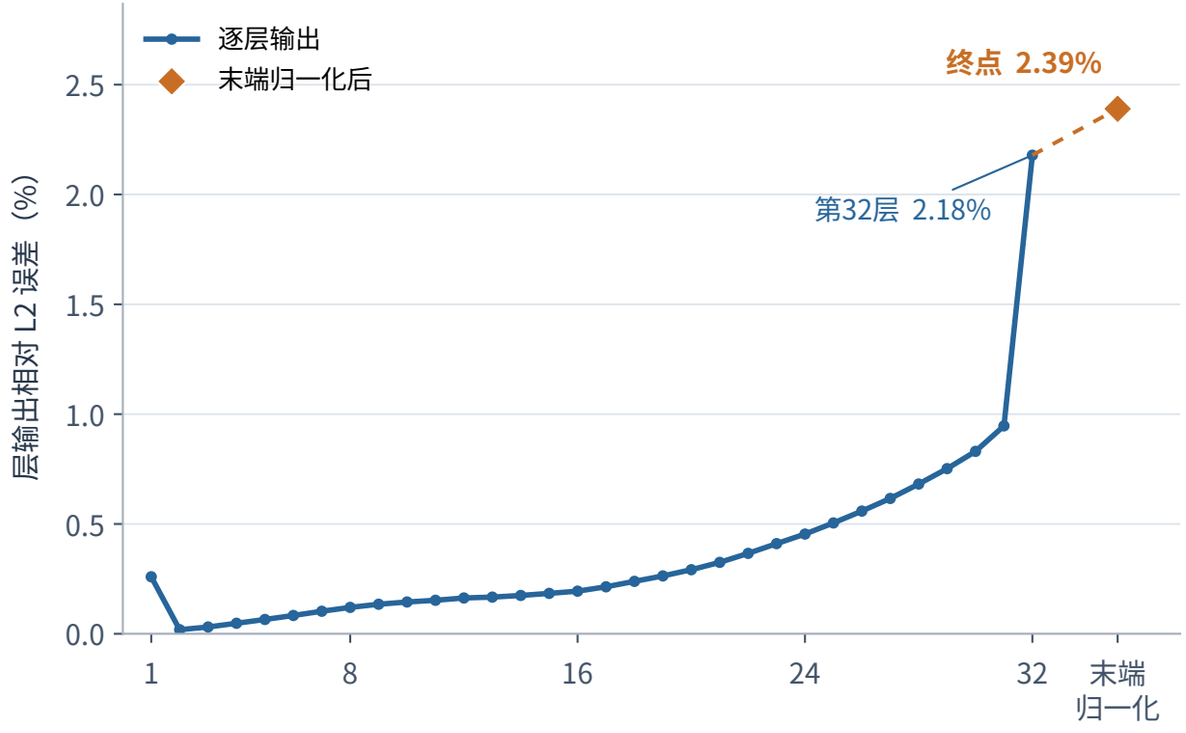
(a) 同输入下，五类算子的局部误差

每类取跨 32 层及调用位置的最大值



(b) 两路连续计算，误差随层传播

各自重算激活量化；一条实测文档曲线



相对 L2 误差 = 100 × ‖ 当前实现 − 参考 ‖ / ‖ 参考 ‖ ；参考保留中间精度，两路采用相同算子出口。

局部比较固定同一输入；传播比较允许后续输入随误差改变。384 个层与调用位置均来自同一篇文档。

采用已接受输出；这些位置不视为独立样本，本图不代表总体统计或逐输出严格误差保证。